Лабораторная работа 1
Выполнила: Короткова Инга Сергеевна

**Цель работы**: анализ практического решения задачи аутентификации пользователя как задачи классификации. Знакомство с набором данных и параметрами. Применение общего теоретического материала по машинному обучению для решения отдельной практической задачи.

Результат представления отчета: фрагмент кода, загружаемый в модуле Загрузить выполненное задание лабораторной работы 1.

Итоговый балл = max((F-мера - 0,5)/0,5\*10, 0)

#### Индивидуальное задание

```
1 #Выбор варианта
 2 fio='Короткова Инга Сергеевна'#ФИО - основа генератора
 3 fio_bytes = fio.encode('utf-8')#Привели в байты
 4 fvar=int.from_bytes(fio_bytes, 'big')#Привели в число
 5 varseed=fvar%1000000000# % - остаток от деления - ядро генератора
 6 vart=fvar%5+1#Получили номер варианта
 1 print("номер варианта: " + str(vart))
    номер варианта:1
 1 leg_ct=[1, 4, 7, 10, 12]#Варианты - число легальных пользователей
 2 big_users = [1,8,9,10,11,14,15,17,18,19,20,22]#пользователи системы с большим числом примеров
 3 friend_users=[]#Список легальных пользователей
 4 allien_users = [2,3,4,5,6,7,12,16,21]#Злоумышленники - изначально с малым количеством примеров
 5 print('Ваше ядро для генератора ',varseed)
 6 print('Ваш номер варианта ',vart)
 7 nmod = 12#сперва 12 пользователей с большим числом примеров
 8 for i in range(1,leg_ct[vart-1]+1,1):#отобрать пользователей в соответствии с вариантом
    nn=fvar%nmod#Отбираем как остаток
    fvar=fvar//nmod#делим ядро для неповторяемости
10
11 friend_users.append(big_users[nn])#Добавляем выбранного пользователя к легальным
12 big_users.pop(nn)#Удаляем добавленного для отсутствия повторов
13
    nmod = nmod - 1#пользователей с большим числом примеров стало меньше
14
15 allien_users=allien_users+big_users #Слили злоумышленников с незадействованными пользователями - для системы они тоже злоумышленники
16 allien_users.sort()#Упорядочили
17 friend_users.sort()#Упорядочили
18 print('Легальные пользователи ', friend_users)
19 print('Нелегальные пользователи ', allien_users)
    Ваше ядро для генератора 951796400
    Ваш номер варианта 1
```

Измените созданную в процессе выполнения нейронную сеть в соответствии со своим вариантом, для этого разделите пользователей на сотрудников и неизвестных и повторите обучение до получения достаточной оценки.

Нелегальные пользователи [2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 14, 15, 16, 17, 18, 19, 20, 21, 22]

```
1 # from google.colab import files
2 # uploaded = files.upload()
3 import pandas as pd
4 df = pd.read_csv('sign_dump.csv')#Загрузили данные. Можно скачать из курса
5 #https://moodle.ido.tsu.ru/mod/resource/view.php?id=27746
6 #слева открыть вклатку Файлы и используя Drag-and-drop подгрузить его в блокнот
```

# Обзорное исследование данных

Легальные пользователи [1]

```
1 df.head() # вывод первых 5 (по умолчанию) строк датасета
2
```

```
precision = precision_m(y_true, y_pred)
recall = recall_m(y_true, y_pred)
return 2*((precision*recall)/(precision+recall+K.epsilon()))
```

#### Подготовка данных

```
1 from tensorflow import keras
 2 from tensorflow.keras.models import Sequential
 3 from tensorflow.keras.layers import Dense
 5 friend_df = df[df['id_user'].isin(friend_users)]
 6 alien df = df[df['id user'].isin(allien users)]#Подписи легальных пользователей и злоумышленников
 8 alien_df['id_user']=0#Идентификатор злоумышленника - 0
10 feed_df=friend_df.merge(alien_df,how='outer')#Объединяем наборы легальных пользователей и злоумышленников
11
12 X = feed_df.drop(columns='id_user')#Входы - параметры
13 Y = feed_df['id_user']#Выходы - пользователи
14
15 from keras.utils import to_categorical
16 dummy_y = to_categorical(Y)#Привели к категориальному типу
17 #Номер пользователя - номер позиции с 1 в массиве
18 #Без этого, например, пользователь 2 - нечно среднее между пользователями 1 и 3
19 #что не является логичным
20 from sklearn.model_selection import train_test_split
21 X_train,X_test,Y_train,Y_test = train_test_split(X,dummy_y)#Разбили выборку на обучающий и тестовый наборы
     /usr/local/lib/python3.6/dist-packages/ipykernel_launcher.py:10: SettingWithCopyWarning:
     A value is trying to be set on a copy of a slice from a DataFrame.
     Try using .loc[row_indexer,col_indexer] = value instead
     See the caveats in the documentation: <a href="https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus">https://pandas.pydata.org/pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus</a>
       # Remove the CWD from sys.path while we load stuff.
```

### - Создание нейронной сети

```
1 model = Sequential()#Сеть с последовательным послойным распространением сигнала
2 model.add(Dense(20,activation='tanh',input_shape=(144,)))#Добавили полносвязный слой. 10 нейронов
3 #активация - relu, число входов - 144, по числу параметров
4 model.add(Dense(dummy_y.shape[1],activation='softmax'))#Добавили полносвязный слой. Число нейронов - число выходов (пользователей)
5 #Функция активации - софтмакс, для нормировки
6 model.compile(
7
  loss='mse',#потери - среднеквадратичная ошибка
8
  optimizer='adam',#оптимизатор adam
9
  metrics=['acc',f1_m,precision_m, recall_m]#метрики - доля верных ответов, F1-мера, точность, полнота
10)
11
1 #Обучение нейронной сети
2 results = model.fit(X_train,Y_train,validation_data = (X_test,Y_test),epochs=50,verbose=1)#Обучаем модель, 100 циклов (эпох), с отобра
 Epoch 11/50
  Epoch 12/50
           =========] - 0s 2ms/step - loss: 0.0872 - acc: 0.8616 - f1_m: 0.8610 - precision_m: 0.8610 - recall_m
  53/53 [=====
  Epoch 13/50
 Epoch 15/50
 Epoch 16/50
 Epoch 17/50
 Epoch 18/50
 Epoch 19/50
 Epoch 20/50
 Epoch 22/50
```

```
7
8 print('Ваш балл равен по базовой формуле из ноутбука', est)
9 print('Ваш балл равен по формуле из формы сдачи задания', est_1)
```

Ваш балл равен по базовой формуле из ноутбука 5 Ваш балл равен по формуле из формы сдачи задания 10

Ваш балл равен по базовой формуле из ноутбука 5.

Ваш балл равен по формуле из формы сдачи задания 10.

#### Заключение

В данной работе был проведен анализ практического решения задачи аутентификации пользователя как задачи классификации.

Мы познакомились с с набором данных и параметрами.

Применили теоретический материал по машинному обучению для решения отдельной практической задачи.

Для этого было сделано следующее:

- сформировано индивидуальное задание на основе генератора случайных чисел (используя фио как базис)
- подготовлен набор данных
- построена и обучена нейросеть
- проведена оценка работы алгоритма
- подсчитан итоговый бал.

```
id_user feature_1 feature_2 feature_3 feature_4 feature_5 feature_6 feature_7 feature_8 feature_9 feature_10 feature_
1 df.info() # Вывод информации о типах данных в таблице, количестве строк, etc.
   <class 'pandas.core.frame.DataFrame'>
   RangeIndex: 2445 entries, 0 to 2444
   Columns: 145 entries, id_user to feature_144
   dtypes: float64(144), int64(1)
   memory usage: 2.7 MB
1 df.describe() # Вывод основных характеристик колонок, таких как количество, среднее, стандартное отклонение, etc.
               id user
                         feature 1
                                     feature 2
                                                  feature 3
                                                              feature 4
                                                                          feature 5
                                                                                       feature 6
                                                                                                   feature 7
                                                                                                                feature 8
                                                                                                                            feature 9
```

count	2445.000000	2445.000000	2445.000000	2445.000000	2445.000000	2445.000000	2445.000000	2445.000000	2445.000000	2445.000000
mean	12.166871	300.392949	5.147635	4.884100	4.735637	4.604194	4.573969	4.460936	4.457551	276.023706
std	6.341351	29.153354	0.145633	0.137199	0.134475	0.163594	0.178485	0.229589	0.200974	31.213146
min	1.000000	91.342100	3.767200	3.557400	2.971400	2.815400	2.605500	2.520500	2.517400	181.646000
25%	8.000000	281.572600	5.041800	4.800900	4.662200	4.514300	4.487300	4.355000	4.341500	257.236200
50%	13.000000	299.933100	5.139800	4.864600	4.732300	4.602500	4.571000	4.470300	4.465000	273.698600
75%	17.000000	319.769900	5.238300	4.945500	4.803500	4.691100	4.678500	4.589200	4.584200	291.531500
max	22.000000	417.005400	5.929300	5.550200	5.377500	5.334400	5.313300	5.209500	5.232500	405.114600

8 rows × 145 columns

```
1 df[df['id_user']==3].head() # получить строки, которые относятся только к 3 пользователю
```

	id_user	feature_1	feature_2	feature_3	feature_4	feature_5	feature_6	feature_7	feature_8	feature_9	feature_10	feature
11	3	294.5275	5.1181	4.8378	4.7183	4.4600	4.5724	4.3305	3.9558	326.5373	4.4391	4.3
12	3	323.4399	5.0062	4.7447	4.6634	4.3905	4.4398	4.1327	4.0659	241.0162	3.9608	4.4
13	3	311.9588	5.0355	4.7367	4.7209	4.4781	4.5233	4.4022	4.3919	234.1416	3.7272	4.3
45	3	304.9742	5.1085	4.7604	4.7493	4.5639	4.3251	4.5185	4.4370	239.7261	3.9647	4.4
78	3	306.4438	5.0856	4.8120	4.7126	4.3959	4.5005	4.4269	4.2703	243.0941	3.7889	4.2

5 rows × 145 columns

# Инициализация генератора случайных чисел в соответствии с вариантом

# ▼ Определение метрик качества работы системы - полнота, точность, F-мера

```
1 from keras import backend as K
 2 def recall_m(y_true, y_pred):#Полнота
      true_positives = K.sum(K.round(K.clip(y_true * y_pred, 0, 1)))
       possible_positives = K.sum(K.round(K.clip(y_true, 0, 1)))
 4
 5
       recall = true_positives / (possible_positives + K.epsilon())
 6
       return recall
 7
 8 def precision_m(y_true, y_pred):#Точность
 9
      true_positives = K.sum(K.round(K.clip(y_true * y_pred, 0, 1)))
10
       predicted_positives = K.sum(K.round(K.clip(y_pred, 0, 1)))
       precision = true positives / (predicted positives + K.epsilon())
11
12
       return precision
13
14 def f1_m(y_true, y_pred):#F1-мера
```

```
Epoch 23/50
Epoch 24/50
Epoch 25/50
Epoch 26/50
Epoch 27/50
Epoch 28/50
Epoch 29/50
Epoch 30/50
Epoch 31/50
Epoch 32/50
Epoch 33/50
Epoch 34/50
Epoch 35/50
Epoch 36/50
Epoch 37/50
Epoch 38/50
Epoch 39/50
```

### Оценка качества работы сети

```
1 import math
 2 loss, accuracy, f1_score, precision, recall = model.evaluate(X_test, Y_test, verbose=2)#выполняем на тестовом наборе, находим получень
 3
 4 import matplotlib.pyplot as plt # импорт модуля для построения графиков
 5 model.save_weights('sign_model.h5')
 6 plt.plot(results.history['f1_m'])#выводим F1-меру для обучающей выборки
 7 plt.plot(results.history['val_f1_m'])#выводим F1-меру для тестовой выборки
 8 plt.title('Model accuracy')
9 plt.ylabel('Accuracy')
10 plt.xlabel('Epoch')
11 plt.legend(['Train', 'Test'], loc='upper left')
12 plt.show()
13
14 import numpy as np
15 from sklearn.metrics import confusion_matrix
16 predicted_outputs = np.argmax(model.predict(X_test), axis=1)
17 expected_outputs = np.argmax(Y_test, axis=1)
18
19 predicted_confusion_matrix = confusion_matrix(expected_outputs, predicted_outputs)
20 predicted_confusion_matrix
```

18/18 - 0s - loss: 0.0257 - acc: 0.9697 - f1 m: 0.9705 - precision m: 0.9705 - recall m: 0.9705

Train Test 0.96 MARAWA 0.94 Accuracy 0.92 0.90 0.88

Model accuracy

```
0.86
                 10
                                                      50
                                             40
                           20
                                    30
                             Epoch
array([[477, 15],
       [ 2, 67]])
```

```
1 #базовый уровень - 0, начальные настройки "кривые, в рамках лабораторных предлагается их понастраивать"
2 #для второго и итогового заданий 0.5 и 0.75 соответственно, множитель 5 - для лабораторных, 10 - для аттестационного.
3 #est=max(0,math.ceil((f1_score-0.75)/(1-0.75)*10))#Находим оценку за задание
4 # est=max(0,math.ceil((f1_score-0)/(1-0)*5))
5 est=max(0, math.ceil((f1_score-0.5)/(1-0.5)*5))
6 \text{ est}_1 = \max(0, \text{ math.ceil}((f1\_score - 0.5)/0.5*10))
```